

دانشگاه تهران
پردیس دانشکده‌های فنی
دانشکده مهندسی برق و کامپیوتر



یادگیری ماشین

تمرین شماره ۱

نام و نام خانوادگی
امیرعلی دهقانی

شماره دانشجویی
۸۱۰۱۰۲۴۴۳

۱۹ آبان ۱۴۰۴

فهرست مطالب

۱	چکیده	۰
۲	پرسش ۱ - Bayes Rule vs. Random Decisions	۱
۲	۱.۱ محاسبه‌ی ریسک برای تصمیم‌های تصادفی	۱
۳	۲.۱ مقایسه‌ی ریسک تصمیم بیز و تصمیم تصادفی	۲
۴	۳.۱ تحت چه شرایطی روی توزیع پسین، دو قاعده تصمیم (بیز و تصادفی) یکسان می‌شوند؟	۳
۴	پرسش ۲ - Bayes Boundaries for Gaussian Classes	۲
۴	۱.۲ اندازه‌گیری ترشهود	۴
۵	۲.۲ دو بعدی	۵
۵	۱.۲.۲ محاسبه‌ی $g_1(x)$ و $g_2(x)$	۵
۶	۲.۲.۲ محاسبه‌ی مرز تصمیم	۶
۷	۳.۲.۲ اثر تغییر پریور و کوواریانس بر مرز تصمیم‌گیری	۷
۷	۴.۲.۲ نمودار از مثالی از ۱۰۰ نقطه و مرز تصمیم‌گیری	۷
۷	پرسش ۳ - Naive Bayes Parameter Estimation (MLE)	۳
۸	۱.۳ محاسبه‌ی تابع Joint Log-Likelihood	۸
۸	۲.۳ فرکانس‌های امپیریکال	۸
۹	پرسش ۴ - Modeling Goals with MLE	۴
۹	۱.۴ محاسبه‌ی احتمال مشاهده‌ی ۶ گل در یک بازی	۹
۱۰	۲.۴ (۳) افزودن بازی ششم با ۸ گل	۱۰
۱۰	پرسش ۵ - MLE Derivation of the Least Squares Loss	۵

۱۰ محاسبه‌ی Likelihood $p(y^{(i)} | x^{(i)}; \theta, \sigma^2)$ ۱.۵

۱۰ معادل بودن با MSE ۲.۵

۶ پرسش ۶ - Effect of Priors on Decision Boundary ۱۱

۷ پرسش ۷ - Naive Bayes Warm-up ۱۲

۱۲ تست تشخیص اعتیاد ۱.۷

۱۲ ۲.۷

۱۲ a ۱.۲.۷

۱۳ b ۲.۲.۷

۱۳ c ۳.۲.۷

۸ پرسش ۸ - Classifying Spam with Naive Bayes ۱۳

۱۴ ۱.۸

۱۴ ۲.۸

۱۴ ۳.۸

۱۵ ۴.۸

۱۶ ۵.۸

۱۷ ۶.۸

۹ پرسش ۹ - Cloud vs. Clear Sky ۱۷

۱۸ معیار جداسازی و قانون تصمیم ۱.۹

۱۸ ارزیابی با ترشهولد میانه ۲.۹

۱۸ تنظیم ترشهولد (ترشهولد بهینه) ۳.۹

۱۹ نمایش و تحلیل خطاها ۴.۹

۱۹ جمع‌بندی ۵.۹

۱۰ مراجع ۲۰

فهرست تصاویر

۷	نقاط و مرز تصمیم‌گیری	۱
۱۷	دقت مدل در برابر مقدار m	۲
۱۹	تصاویر misclassified	۳

فهرست جداول

۱	پنج واژهٔ محتمل‌تر در هر کلاس بر اساس $P(w \mid \text{class})$	۱۵
---	--	----

به طور کلی در این تمرین به مرور ۳ فایل اول پرداخته شده است و سوالات مطرح شده در هر بخش به صورت کامل پاسخ داده شده است. در بخش اول به مقایسه‌ی دو قاعده‌ی تصمیم بیز و تصمیم تصادفی پرداخته شده است و نشان داده شده است که قانون بیز همیشه ریسک کمتری دارد. در بخش دوم به محاسبه‌ی مرز تصمیم برای دو کلاس گوسی با واریانس برابر پرداخته شده است و همچنین اثر تغییر پریور و کوواریانس بر مرز تصمیم‌گیری بررسی شده است. در بخش سوم به محاسبه‌ی تابع Joint Log-Likelihood برای مدل Naive Bayes پرداخته شده است و فرکانس‌های امپیریکال برای پارامترهای مدل محاسبه شده است. در بخش چهارم به محاسبه‌ی پارامتر MLE برای مدل پواسون پرداخته شده است و احتمال مشاهده‌ی ۶ گل در یک بازی محاسبه شده است. در نهایت در بخش پنجم به اثبات اینکه کمینه کردن خطای مربعات برابر با بیشینه کردن تابع Likelihood است، پرداخته شده است. در سوال ۶ ام، اثر تغییرات پسین‌ها بر مرز تصمیم‌گیری بررسی شده است. در سوال ۷، مسئله‌ی ساده‌ای از قانون بیز حل شده است که نشان بدهد لزوماً اگر $P(A|B)$ بزرگ باشد، آنگاه لزوماً $P(B|A)$ خیلی بزرگ یا دقیق نیست. در سوال ۸، مسئله‌ی دیگری از قانون بیز حل شده است که نشان می‌دهد با داشتن اطلاعات بیشتر، احتمال وقوع یک رویداد می‌تواند کاهش یابد. در نهایت در سوال ۹، به بررسی ویژگی گرمای عکس برای تشخیص آسمان ابری و صاف پرداخته شده است و نتایج حاصل از این ویژگی تحلیل شده است.

پرسش 1 - Bayes Rule vs. Random Decisions

$$\alpha_{Bayes}(x) = \omega^* = \arg \max_i P(\omega_i | x) \quad \alpha_{rand}(x) = \omega \sim p(\omega | x)$$
$$R(x) = 1 - P_{\text{right_decision}}$$

۱.۱ محاسبه‌ی ریسک برای تصمیم‌های تصادفی

ابتدا باید تصمیم درست را در این حالت محاسبه کنیم: تصمیم ما زمانی درست است که کلاس واقعی ω_i باشد و تصمیم ما هم ω_i باشد. احتمال این اتفاق برابر است با:

$$\begin{aligned} P_{\text{right_decision}} &= \sum_i P(\omega_i | x) P(\alpha_{rand}(x) = \omega_i | x) \\ &= \sum_i P(\omega_i | x) P(\omega_i | x) \\ &= \sum_i P(\omega_i | x)^2 \end{aligned}$$

حال با جایگذاری در فرمول ریسک، داریم:

$$R_{rand}(x) = 1 - \sum_i P(\omega_i | x)^2$$

۲.۱ مقایسه‌ی ریسک تصمیم بیز و تصمیم تصادفی

در ابتدا باید ریسک تصمیم بیز را محاسبه کنیم. در این حالت تصمیم درست حالتی است که بیشترین احتمال پسین را داشته باشیم. بنابراین:

$$P_{\text{right_decision}} = \max_i P(\omega_i | x)$$

و ریسک به صورت زیر خواهد بود:

$$R_{\text{Bayes}}(x) = 1 - \max_i P(\omega_i | x)$$

حال باید نشان دهیم که $R_{\text{Bayes}}(x) \leq R_{\text{rand}}(x)$:

$$\begin{aligned} 1 - \sum_i P(\omega_i | x)^2 &\geq 1 - \max_i P(\omega_i | x) \\ \Rightarrow \sum_i P(\omega_i | x)^2 &\leq \max_i P(\omega_i | x) \end{aligned}$$

و چون که $0 \leq P(\omega_i | x) \leq 1$ ، مربع آن کوچک‌تر می‌شود و همچنین چون که برای هر $P(\omega_i | x)$ ، $\max_i P(\omega_i | x)$ بزرگ‌تر یا مساوی است، پس نامساوی برقرار است و اثبات کامل می‌شود.

پس نتیجه می‌گیریم که قانون بیز همیشه کمترین ریسک را دارد و تصمیم تصادفی فقط در شرایط خاصی همان ریسک را دارد.

۳.۱ تحت چه شرایطی روی توزیع پسین، دو قاعده تصمیم (بیز و تصادفی) یکسان می‌شوند؟

در شرایطی که $P(\omega_i | x)$ به صورت یک توزیع یکنواخت باشد. اگر فرض کنیم که ما k نقطه داریم، در این صورت:

$$\sum_i^k P(\omega_i | x)^2 = k * \left(\frac{1}{k}\right)^2 = \frac{1}{k} = \max_i P(\omega_i | x)$$

در این حالت می‌توان گفت که ریسک هر دو حالت نیز با یکدیگر برابر می‌شود و این دو یکسان می‌شوند.

پرسش 2 - Bayes Boundaries for Gaussian Classes

۱.۲ اندازه‌گیری ترشهولد

ما دو کلاس با توزیع نرمال به صورت زیر داریم که واریانس این دو باهم یکی است:

$$p(x | \omega_1) = \mathcal{N}(0, \sigma^2) \quad p(x | \omega_2) = \mathcal{N}(1, \sigma^2)$$

نقاط مرزی جاهایی هستند که احتمال پسین دو کلاس برابر باشد: بنابراین:

$$R(\alpha_1 | x) = R(\alpha_2 | x)$$

می‌دانیم که فرمول ریسک به صورت زیر است:

$$R(\alpha_i | x) = \sum_j \lambda(\alpha_i | \omega_j) P(\omega_j | x)$$

$$\Rightarrow \sum_j \lambda(\alpha_1 | \omega_j) P(\omega_j | x) = \sum_j \lambda(\alpha_2 | \omega_j) P(\omega_j | x)$$

با توجه به اینکه $\lambda_{11} = \lambda_{22} = 0$

$$\lambda_{12} P(\omega_2 | x) = \lambda_{21} P(\omega_1 | x)$$

حال با جایگذاری فرمول احتمال پسین، داریم:

$$\lambda_{12} \frac{p(x | \omega_2) P(\omega_2)}{p(x)} = \lambda_{21} \frac{p(x | \omega_1) P(\omega_1)}{p(x)}$$

$$\xrightarrow{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}} \frac{\cancel{\frac{1}{\sqrt{2\pi}\sigma}} e^{-\frac{(x-1)^2}{2\sigma^2}} \lambda_{12} P(\omega_2)}{\cancel{p(x)}} = \frac{\cancel{\frac{1}{\sqrt{2\pi}\sigma}} e^{-\frac{x^2}{2\sigma^2}} \lambda_{21} P(\omega_1)}{\cancel{p(x)}}$$

$$\xrightarrow{\ln} \ln(\lambda_{12} P(\omega_2)) - \frac{(x-1)^2}{2\sigma^2} = \ln(\lambda_{21} P(\omega_1)) - \frac{x^2}{2\sigma^2}$$

$$\rightarrow \ln\left(\frac{\lambda_{12} P(\omega_2)}{\lambda_{21} P(\omega_1)}\right) = \frac{1-2x}{2\sigma^2}$$

$$\Rightarrow \tau = x = \frac{1}{2} - \sigma^2 \ln\left(\frac{\lambda_{12} P(\omega_2)}{\lambda_{21} P(\omega_1)}\right)$$

۲.۲ دوبعدی

۱.۲.۲ محاسبه‌ی $g_1(x)$ و $g_2(x)$

$$\mu_1 = (4, 11) \quad \mu_2 = (10, 3)$$

$$\sum = 3I$$

$$P(\omega_1) = 0.6 \quad P(\omega_2) = 0.4$$

$$g_i(x) = \ln(P(x | \omega_i)) + \ln(P(\omega_i))$$

$$\ln(P(x | \omega_i)) = -\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(|\sum|) - \frac{1}{2} (x - \mu_i)^T \sum^{-1} (x - \mu_i)$$

$$\xrightarrow{\text{با جایگذاری } g_i(x)} g_i(x) = -\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln(|\sum|) - \frac{1}{2} (x - \mu_i)^T \sum^{-1} (x - \mu_i) + \ln(P(\omega_i))$$

جملات ثابت را حذف می‌کنیم:

$$g_i(x) = -\frac{1}{2} (x - \mu_i)^T \sum^{-1} (x - \mu_i) + \ln(P(\omega_i))$$

$$\rightarrow g_i(x) = x^T \sum^{-1} \mu_i - \frac{1}{2} \mu_i^T \sum^{-1} \mu_i + \ln(P(\omega_i))$$

$$\xrightarrow{\sum = 3I \Rightarrow \sum^{-1} = \frac{1}{3} I}$$

$$g_i(x) = \frac{1}{3} x^T \mu_i - \frac{1}{6} |\mu_i|^2 + \ln(P(\omega_i))$$

$$\begin{cases} g_1(x) = \frac{4}{3}x_1 + \frac{11}{3}x_2 - \frac{16+121}{6} + \ln(0.6) \\ g_2(x) = \frac{10}{3}x_1 + x_2 - \frac{100+9}{6} + \ln(0.4) \end{cases}$$

۲.۲.۲ محاسبه‌ی مرز تصمیم

به دنبال مرز هستیم بنابراین $g_1(x) = g_2(x)$:

$$\frac{4}{3}x_1 + \frac{11}{3}x_2 - \frac{16+121}{6} + \ln(0.6) = \frac{10}{3}x_1 + x_2 - \frac{100+9}{6} + \ln(0.4)$$

$$\rightarrow -2x_1 + \frac{8}{3}x_2 - \frac{28}{6} + \ln\left(\frac{0.6}{0.4}\right) = 0$$


$$\rightarrow -6x_1 + 8x_2 - 14 + 3\ln(1.5) = 0$$

$$\Rightarrow x_2 = \frac{3}{4}x_1 + \frac{14 - 3\ln(1.5)}{8}$$

۳.۲.۲ اثر تغییر پریور و کوواریانس بر مرز تصمیم‌گیری

به دلیل اینکه کوواریانس‌ها برابر است، مرز تصمیم خطی است و شیب آن ثابت است. در نتیجه با تغییر پریور‌ها فقط ترم بایاس $\ln(\frac{P(\omega_1)}{P(\omega_2)})$ تغییر می‌کند که باعث جابجایی خط مرز تصمیم می‌شود ولی شیب آن ثابت می‌ماند.

۴.۲.۲ نمودار از مثالی از ۱۰۰ نقطه و مرز تصمیم‌گیری



شکل ۱: نقاط و مرز تصمیم‌گیری

پرسش ۳ - Naive Bayes Parameter Estimation (MLE)

$$\phi_y = P(y = 1) \quad \phi_{j|y=0} = P(x_j = 1 \mid y = 0) \quad \phi_{j|y=1} = P(x_j = 1 \mid y = 1)$$

۱.۳ محاسبه‌ی تابع Joint Log-Likelihood

$$\begin{aligned}
 Z &= \{(x^{(i)}, y^{(i)})\}_{i=1}^n \\
 L(\phi) &= P(Z; \phi) = P(y^{(i)}; \phi_y) \prod_{j=1}^n P(x_j^{(i)} | y^{(i)}; \phi_{j|y=0}, \phi_{j|y=1}) \\
 P(x_j^{(i)} | y^{(i)}; \phi_{j|y=0}, \phi_{j|y=1}) &= (\phi_{j|y=1})^{x_j^{(i)}} (1 - \phi_{j|y=1})^{1-x_j^{(i)}} \\
 P(Z; \phi) &= P(y^{(i)}; \phi_y) \prod_{j=1}^n \left[(\phi_{j|y=1})^{x_j^{(i)}} (1 - \phi_{j|y=1})^{1-x_j^{(i)}} \right]^{y^{(i)}} \\
 \rightarrow \ell(\phi) &= \sum_{i=1}^n \left[\ln P(y^{(i)}; \phi_y) + \sum_{j=1}^n y^{(i)} \left(x_j^{(i)} \ln \phi_{j|y=1} + (1 - x_j^{(i)}) \ln(1 - \phi_{j|y=1}) \right) \right] \\
 \ln P(y^{(i)}; \phi_y) &= y^{(i)} \ln \phi_y + (1 - y^{(i)}) \ln(1 - \phi_y) \\
 \ell(\phi) &= \sum_{i=1}^n \left[y^{(i)} \ln(\phi_y) + (1 - y^{(i)}) \ln(1 - \phi_y) \right] + \\
 &\quad \sum_{i=1}^n \sum_{j=1}^m y^{(i)} \left[x_j^{(i)} \ln(\phi_{j|y=1}) + (1 - x_j^{(i)}) \ln(1 - \phi_{j|y=1}) \right] + \\
 &\quad \sum_{i=1}^n \sum_{j=1}^m (1 - y^{(i)}) \left[x_j^{(i)} \ln(\phi_{j|y=0}) + (1 - x_j^{(i)}) \ln(1 - \phi_{j|y=0}) \right]
 \end{aligned}$$

۲.۳ فرکانس‌های امپیریکال

باید از $\ell(\phi)$ نسبت به هریک از پارامترها مشتق ضمنی بگیریم:

$$\frac{\partial \ell(\phi)}{\partial \phi_y} = \sum_i^n \left[\frac{y^{(i)}}{\phi_y} - \frac{1 - y^{(i)}}{1 - \phi_y} \right] = 0 \rightarrow \phi_y = \frac{1}{n} \sum_i^n y^{(i)}$$

$$\frac{\partial \ell(\phi)}{\partial \phi_{j|y=1}} = \sum_{i:y^{(i)}=1} \left[\frac{x_j^{(i)}}{\phi_{j|y=1}} - \frac{1 - x_j^{(i)}}{1 - \phi_{j|y=1}} \right] \Rightarrow \hat{\phi}_{j|y=1} = \frac{\sum_{i:y^{(i)}=1} x_j^{(i)}}{\sum_{i=1}^n y^{(i)}}.$$

$$\frac{\partial \ell(\phi)}{\partial \phi_{j|y=0}} = \sum_{i:y^{(i)}=0} \left[\frac{x_j^{(i)}}{\phi_{j|y=0}} - \frac{1 - x_j^{(i)}}{1 - \phi_{j|y=0}} \right] \Rightarrow \hat{\phi}_{j|y=0} = \frac{\sum_{i:y^{(i)}=0} x_j^{(i)}}{\sum_{i=1}^n (1 - y^{(i)})}.$$

پرسش 4 - Modeling Goals with MLE

$$(x_i | \lambda) \sim Poi \rightarrow P(x_i | \lambda) = e^{-\lambda} \frac{\lambda^{x_i}}{x_i!}$$

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \Rightarrow$$

$$\ell(\lambda) = \left(\sum_{i=1}^n x_i \right) \ln \lambda - n\lambda - \sum_{i=1}^n \ln(x_i!)$$

$$\rightarrow \frac{d\ell}{d\lambda} = \frac{\sum_{i=1}^n x_i}{\lambda} - n = 0 \Rightarrow \hat{\lambda} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

۱.۴ محاسبه‌ی احتمال مشاهده‌ی ۶ گل در یک بازی

$$P(X=6 | \hat{\lambda}) = e^{-2.6} \frac{2.6^6}{6!} \approx 0.0319$$

۲.۴ (۳) افزودن بازی ششم با ۸ گل

$$\hat{\lambda} = \frac{2 + 4 + 6 + 0 + 1 + 8}{6} = 3.5 \quad P(X = 6 \mid \hat{\lambda} = 3.5) = e^{-3.5} \frac{3.5^6}{6!} \approx 0.0771$$

پرسش ۵ - MLE Derivation of the Least Squares Loss

۱.۵ محاسبه‌ی Likelihood $p(y^{(i)} \mid x^{(i)}; \theta, \sigma^2)$

$$y^{(i)} = \theta^\top x^{(i)} + \varepsilon^{(i)}, \quad \varepsilon^{(i)} \sim \mathcal{N}(0, \sigma^2)$$

اگر که $\varepsilon^{(i)}$ نرمال باشد، $\theta^\top x^{(i)}$ یک ثابت است که درواقع توزیع را شیف‌ت می‌دهد و آنگاه $y^{(i)}$ نیز نرمال خواهد بود:

$$p(y^{(i)} \mid x^{(i)}; \theta, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y^{(i)} - \theta^\top x^{(i)})^2}{2\sigma^2}\right)$$

۲.۵ معادل بودن با MSE

$$p(y \mid X, \theta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y^{(i)} - \theta^\top x^{(i)})^2}{2\sigma^2}\right)$$
$$\ell(\theta) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y^{(i)} - \theta^\top x^{(i)})^2 \equiv \sum_{i=1}^n (y^{(i)} - \theta^\top x^{(i)})^2$$

به همان MSE می‌رسیم. بنابراین ماکزیمم کردن $\ell(\theta)$ ، معادل کمینه کردن خطا (MSE) است.

پرسش 6 - Effect of Priors on Decision Boundary

برای دو توزیع گوسی یک‌بعدی با واریانس برابر σ^2 :

$$p(x | \omega_1) = \mathcal{N}(\mu_1, \sigma^2), \quad p(x | \omega_2) = \mathcal{N}(\mu_2, \sigma^2)$$

مرز تصمیم بیز از تساوی پسین‌ها:

$$\begin{aligned} p(x | \omega_1)P(\omega_1) &= p(x | \omega_2)P(\omega_2) \\ \Rightarrow x^* &= \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_2 - \mu_1} \ln \frac{P(\omega_2)}{P(\omega_1)}. \end{aligned}$$

با افزایش $P(\omega_1)$ ، مقدار $\ln \frac{P_2}{P_1}$ کاهش یافته و x^* به سمت μ_2 جابه‌جا می‌شود.

۱.۷ تست تشخیص اعتیاد

$$\begin{aligned}
 P(T = 1 \mid D = 1) &= 0.99, & P(T = 0 \mid D = 0) &= 0.99, & P(D = 1) &= 0.001 \\
 P(D = 1 \mid T = 1) &= \frac{P(T = 1 \mid D = 1) P(D = 1)}{P(T = 1 \mid D = 1) P(D = 1) + P(T = 1 \mid D = 0) P(D = 0)} \\
 P(T = 1 \mid D = 0) &= 1 - 0.99 = 0.01 \\
 P(D = 0) &= 1 - 0.001 = 0.999 \\
 \Rightarrow P(D = 1 \mid T = 1) &= \frac{0.99 \times 0.001}{0.99 \times 0.001 + 0.01 \times 0.999} \approx 0.0902.
 \end{aligned}$$

نتیجه: با وجود دقت بالای تست، احتمال واقعی اعتیاد فردی که تستش مثبت است تنها حدود 9% می باشد.

۲.۷

a ۱.۲.۷

$$P(y = 1) = \frac{5}{10} = 0.5 \quad P(y = 0) = \frac{5}{10} = 0.5$$

b ۲.۲.۷

$$\begin{aligned} P(x_1 = 1 \mid y = 1) &= \frac{4}{5} = 0.8 & P(x_2 = 1 \mid y = 1) &= \frac{5}{5} = 1 \\ P(x_1 = 1 \mid y = 0) &= \frac{3}{5} = 0.6 & P(x_2 = 1 \mid y = 0) &= \frac{0}{5} = 0 \end{aligned}$$

c ۳.۲.۷

برای $x = [1, 1]$ ، با فرض استقلال شرطی ویژگی‌ها در مدل Bayes Naive داریم:

$$P(y = 1 \mid x) \propto P(y = 1) P(x_1 = 1 \mid y = 1) P(x_2 = 1 \mid y = 1)$$

$$P(y = 0 \mid x) \propto P(y = 0) P(x_1 = 1 \mid y = 0) P(x_2 = 1 \mid y = 0)$$

$$s_1 = 0.5 \times 0.8 \times 1 = 0.4$$

$$s_0 = 0.5 \times 0.6 \times 0 = 0$$

$$P(y = 1 \mid x) = \frac{s_1}{s_1 + s_0} = \frac{0.4}{0.4} = 1, \quad P(y = 0 \mid x) = 0.$$

نتیجه‌گیری: Label محتمل‌تر برای نمونه‌ی تست $x = [1, 1]$ برابر با $y = 1$ است.

پرسش 8 - Classifying Spam with Naive Bayes

۱.۸

برای محاسبه‌ی احتمال هرکدام، باید در ابتدا تمام نمونه‌های Training ای که دارای آن ویژگی هستند را بشماریم و سپس بر تعداد کل نمونه‌ها تقسیم کنیم.

$$P(Spam) = \frac{\text{Number of Spam Emails}}{\text{Total Number of Emails}}$$

$$P(Ham) = \frac{\text{Number of Ham Emails}}{\text{Total Number of Emails}} = 1 - P(Spam)$$

۲.۸

Total emails: 9000 Spam emails: 5163 Ham emails: 3837

$$P(spam) = 0.5737 \quad P(ham) = 0.4263$$

۳.۸

ساخت مجموعه‌ی واژگان و شمارش‌ها. از روی فایل train، برای هر سطر لیبل ham/spam را می‌خوانیم و زوج‌های word-count را جمع می‌زنیم. دو شمارنده تعریف می‌کنیم:

$$n_i^{(spam)} = \text{تعداد وقوع واژه } w_i \text{ در همه ایمیل‌های spam,}$$

$$n_i^{(ham)} = \text{تعداد وقوع واژه } w_i \text{ در همه ایمیل‌های ham.}$$

همچنین

$$N_{spam} = \sum_i n_i^{(spam)} \quad N_{ham} = \sum_i n_i^{(ham)}$$

و مجموعه‌ی واژگان را V می‌گیریم که شامل همه کلماتِ ظاهرشده در آموزش است؛ اندازه آن $|V|$ است.

هموارسازی با m-estimate. برای حذف صفرها، مطابق دستورکار از

$$m = |V|, \quad p = \frac{1}{|V|}$$

استفاده می‌کنیم و می‌نویسیم:

$$P(w_i | \text{spam}) = \frac{n_i^{(\text{spam})} + m p}{N_{\text{spam}} + m}, \quad P(w_i | \text{ham}) = \frac{n_i^{(\text{ham})} + m p}{N_{\text{ham}} + m}.$$

کلمات شاخص هر کلاس. پس از محاسبه این احتمال‌ها، واژه‌ها را برحسب $P(w | \text{class})$ مرتب می‌کنیم و ۵ واژه محتمل‌تر هر کلاس را گزارش می‌کنیم (همان خروجی چاپ‌شده‌ی کد).

واژه	$P(w \text{spam})$	$P(w \text{ham})$
enron	0.038	—
a	0.024	—
corp	0.022	—
the	0.021	—
to	0.020	—
aa...a	—	0.044
enron	—	0.042
the	—	0.033
to	—	0.025
a	—	0.017

جدول ۱: پنج واژه محتمل‌تر در هر کلاس بر اساس $P(w | \text{class})$.

۴.۸

برای هر ایمیل تست، به جای محاسبه مستقیم $P(\text{spam} | w_1, \dots, w_n)$ و $P(\text{ham} | w_1, \dots, w_n)$ که به دلیل ضرب تعداد زیادی احتمال کوچک دچار مشکل دقت عددی می‌شوند، نمره لاگ احتمال را مقایسه می‌کنیم. نمره‌ها به صورت زیر تعریف می‌شوند:

$$S_{\text{spam}}(x) = \log P(\text{spam}) + \sum_{w \in x} \text{count}(w, x) \log P(w | \text{spam}),$$

$$S_{\text{ham}}(x) = \log P(\text{ham}) + \sum_{w \in x} \text{count}(w, x) \log P(w | \text{ham}).$$

قاعده تصمیم:

$$\hat{y}(x) = \begin{cases} \text{spam} & S_{\text{spam}}(x) \geq S_{\text{ham}}(x), \\ \text{ham} & \text{در غیر این صورت.} \end{cases}$$

در پیاده‌سازی، $\log P(\text{spam})$ و $\log P(\text{ham})$ از پیشین‌ها محاسبه شده و برای هر کلمه حاضر در ایمیل، $\log P(w \mid \text{class})$ به تناسب تعداد تکرار آن جمع می‌شود؛ کلماتی که در واژگان نیستند نادیده گرفته می‌شوند.

دقت (Accuracy) روی داده تست به صورت درصد نمونه‌های درست طبقه‌بندی شده گزارش

می‌شود:

$$\text{Accuracy} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} \mathbf{1}\{\hat{y}(x_i) = y_i\} \times 100.$$

۵.۸

برای بررسی اثر پارامتر m ، آن را مطابق دستور کار به صورت

$$m = |V| \times [1, 10, 100, 1000, 10000]$$


تغییر دادیم. برای هر مقدار m ، احتمال‌های شرطی کلمات را با برآورد m -estimate دوباره محاسبه کردیم:

$$P(w_i \mid \text{spam}) = \frac{n_i^{(\text{spam})} + mp}{N_{\text{spam}} + m}, \quad P(w_i \mid \text{ham}) = \frac{n_i^{(\text{ham})} + mp}{N_{\text{ham}} + m},$$

و سپس دقت classification accuracy را روی test set محاسبه نمودیم.

وقتی m خیلی کوچک است، مدل تقریباً فقط به شمارش‌های مشاهده شده تکیه می‌کند؛ یعنی کلمات نادیده گرفته شده یا کم‌تکرار در یک کلاس احتمال خیلی کوچک می‌گیرند. این می‌تواند به overfitting و حساسیت به نویز/واژه‌های کم‌تکرار منجر شود. وقتی m خیلی بزرگ است، احتمال‌ها به $\frac{1}{|V|}$ نزدیک می‌شوند و مدل اطلاعات خاص داده را «بیش از حد هموار» می‌کند؛ نتیجه آن underfitting است. بنابراین معمولاً دقت تست در یک m میانی به بیشینه می‌رسد که توازن bias-variance را برقرار می‌کند.

نتایج. نمودار زیر دقت مدل را در برابر m نشان می‌دهد.



شکل ۲: دقت مدل در برابر مقدار m

۶.۸

مثلا می‌توان حروف را جایگزین کرد. مثلا به جای حرف a از @ استفاده کرد. یا می‌توان از اعداد به جای حروف استفاده کرد. مثلا به جای حرف o از عدد ۰ استفاده کرد. همچنین می‌توان از کلمات مشابه استفاده کرد. مثلا به جای کلمه free از کلمه freee استفاده کرد. یکی از راه‌های دیگر، شکستن کلمات است. مثلا به جای کلمه free می‌توان از f r e e استفاده کرد. همچنین می‌توان از حروف بزرگ و کوچک به جای هم استفاده کرد. مثلا به جای کلمه Free از کلمه free استفاده کرد.

پرسش ۹ - Cloud vs. Clear Sky

بر اساس اینکه همیشه در برنامه‌های ادیت، گزینه‌ی Warmth رو دیدم، تصمیم گرفتم که از این ویژگی استفاده کنم.

۱.۹ معیار جداسازی و قانون تصمیم

برای هر تصویر، نمره $warmth$ را به صورت

$$\text{score} = \overline{R} - \overline{B}$$

تعریف می‌کنیم که در آن $\overline{R}$ و $\overline{B}$ به ترتیب میانگین کانال‌های R و B (پس از نرمال‌سازی $[0, 1]$) هستند. شهود: تصاویر آفتابی (warm) معمولاً مؤلفه قرمز بیشتری نسبت به آبی دارند و برعکس برای تصاویر ابری (cold).

اگر $\text{score} \geq \text{median}(\text{scores})$ آنگاه لیبل warm وگرنه cold. لیبل‌های مبنا (ground truth) از نام فایل‌ها استخراج شده‌اند: نام‌های شروع‌شونده با s به‌عنوان warm و سایرین cold.

۲.۹ ارزیابی با ترشهولد میانه

برای پیش‌بینی، ترشهولد $\tau_{\text{med}} = \text{median}(\text{scores})$ را روی کل تصاویر اعمال می‌کنیم و سپس Confusion Matrix و پارامترهای Precision، Recall و Accuracy (با کلاس مثبت = warm) را چاپ می‌کنیم. این بخش متناظر با چاپ‌های:

● TP, FP, TN, FN در خط “Confusion matrix (positive = warm)”

● Accuracy, Recall (warm), Precision (warm)

اعداد دقیق همان خروجی‌های سلول ارزیابی با ترشهولد میانه هستند.

۳.۹ تنظیم ترشهولد (ترشهولد بهینه)

برای بهبود عملکرد، روی همه مقادیر یکتای scores جست‌وجو کرده و ترشهولدا را انتخاب می‌کنیم که Accuracy را بیشینه کند:


$$\tau_{\text{opt}} = \arg \max_{\tau} \text{Accuracy}(\mathbf{1}\{\text{score} \geq \tau\}).$$

سپس با همین ترشهولد بهینه، Confusion Matrix و Precision/Recall/Accuracy دوباره چاپ می‌کنیم این بخش نشان می‌دهد صرفاً با تنظیم مرز تصمیم، مدل تک‌ویژگی $warmth$ نیز بهبود می‌یابد.

۴.۹ نمایش و تحلیل خطاها

تصاویر misclassified نمایش داده می‌شوند و علت این اشتباهات به شرح زیر است.

- نور سردِ ظهر (آسمان آبی غالب) ولی بدون ابر واضح $\Rightarrow \bar{R} - \bar{B}$ کوچک و تمایل به cold.
- غروب/ابری گرم (ابرهای نارنجی) $\Rightarrow \bar{R} - \bar{B}$ بزرگ و تمایل به warm.
- تغییر white balance/ادیت، یا نواحی وسیع بی‌رنگ (مه/برف) که میانگین‌ها را به خاکستری می‌کشند.



شکل ۳: تصاویر misclassified

۵.۹ جمع‌بندی

تصمیم‌گیری بر اساس گرمای عکس ساده، سریع و قابل توضیح است و با ترشهولد میانه عملکرد پایه‌ای خوبی می‌دهد؛ تنظیم ترشهولد به مقدار بهینه (τ_{opt}) معمولاً Accuracy را بالاتر می‌برد. محدودیت‌ها عمدتاً از حساسیت به نور محیطی و white balance ناشی می‌شوند؛ برای بهبودهای بعدی (در صورت نیاز) می‌توان ترکیب ساده‌ای از روشنایی یا کانال‌های رنگی دیگر را نیز در همین چارچوب قانون ترشهولد اضافه کرد..

- Fundamentals of Data - 2024 - Dr Dehaqani
- Bayesian Decision Theory - 2024 - Dr Dehaqani
- Parametric Models I - MLE and Bayesian density estimation - 2024 - Dr Dehaqani
- Pillow 12.0.0 documentation